

把AI智能体培养成研究生：面向核物理研究的五层个人知识架构

金磊^{1,2}

1 (同济大学物理科学与工程学院 上海 200092)

2 (中国科学院近代物理研究所南方核科学理论研究中心 广东惠州 516000)

摘要 面向核物理研究的人工智能智能体若只依赖单次会话，难以保存研究方向、已读文献、代码约束、失败经验和验证标准。针对这一问题，构建了由纯文本与版本控制、常驻个人档案、概念笔记与统一词表、可复用技能、反馈记忆组成的五层个人知识架构，并以入库、查询和体检三类操作形成读取、执行、写回的闭环。实际部署已积累571篇精读文献、365个实体页、195个方法页及1425个图谱节点，并支持带来源的研究问答和可审计综述初稿生成。结果表明，科研智能体的长期价值主要来自可追溯上下文的持续积累，而非单次模型能力。该架构同时给出摘要损失、概念分裂、单源错误、并发冲突和保密风险的控制方法，为AI Agent与vibe coding进入可复现核物理研究提供实践路径。

关键词 AI智能体；核物理；个人知识库；科研工作流；vibe coding；可复现研究

中图分类号 TL99；TP18

Training an AI Agent Like a Graduate Student: A Five-Layer Personal Knowledge Architecture for Nuclear-Physics Research

JIN Lei^{1,2}

1 (School of Physics Science and Engineering, Tongji University, Shanghai 200092, China)

2 (Southern Center for Nuclear-Science Theory (SCNT), Institute of Modern Physics, Chinese Academy of Sciences, Huizhou 516000, Guangdong Province, China)

Abstract [Background]: Artificial-intelligence agents used in nuclear-physics research often lose the researcher's literature, code constraints, failed ideas, and validation standards when a session ends. [Purpose]: A persistent and auditable architecture is developed to turn one-off agent assistance into cumulative research infrastructure. [Methods]: The architecture contains five layers: plain text and version control, an always-loaded researcher profile, a concept wiki with a controlled vocabulary, reusable skills, and feedback memory. Ingest, query, and lint operations close the read, act, and write-back loop. [Results]: A nuclear-theory deployment has accumulated 571 deeply read papers, 365 entity pages, 195 method pages, and a graph of 1,425 nodes. It supports source-grounded research answers and an auditable review-draft workflow. [Conclusions]: The long-term value of a research agent comes primarily from persistent, traceable context and disciplined write-back, rather than from one-session model capability. The proposed controls address summarization loss, concept splitting, single-source error, concurrent edits, and confidentiality.

Key words AI agent; Nuclear physics; Personal knowledge base; Research workflow; Vibe coding; Reproducible research

基金项目：国家自然科学基金项目（12475132）资助

第一作者：金磊，男，博士，教授，研究领域为核反应理论及机器学习在核物理中的应用

通讯作者：金磊，E-mail: jinl@tongji.edu.cn

收稿日期：待编辑部填写，修回日期：待编辑部填写

XXXXXX-1

以大语言模型（large language model, LLM）为核心的人工智能（artificial intelligence, AI）智能体，已经从文本生成扩展到检索、推理、调用工具和操作代码仓库。检索增强生成（retrieval-augmented generation, RAG）用外部文档补充参数化知识，缓解知识更新和来源追溯问题[1]；ReAct把推理轨迹与外部行动交替组织，使模型能够查询知识库和环境[2]。随后出现的生成式智能体和Reflexion进一步表明，自然语言形式的经验记录、反思与情景记忆可以改变后续行为[3-4]。在科学研究中，ChemCrow和Coscientist已把LLM与专业软件、数据库及实验设备连接起来[5-6]，AI Scientist则尝试覆盖选题、编码、实验、写作和模拟评审的完整流程[7]。

这些工作说明智能体可以执行复杂任务，但科研中的长期瓶颈不只在单次推理能力。一个会话内表现出色的模型，在新会话中往往不知道研究者的方向、已读文献、现有代码、否决过的想法和验证标准。若每次都从原始文件重新检索，综合工作会被反复计算；若把每次聊天全部保存，又会积累大量临时尝试、过期假设和未经核验的判断。对核物理而言，这一问题更突出：一个结论常常依赖特定反应体系、近似层级、势参数、边界条件和数值收敛标准，脱离这些上下文的“正确答案”并不一定具有物理意义。

Vibe coding降低了程序开发门槛，但科研代码不能停在“能跑”。它还必须回答输入从哪里来、与哪个基准一致、误差是否收敛、修改影响了哪些结果、失败路径为何被放弃。为此，需要把一次性的对话式能力改造成可积累、可审计、可迁移的研究能力。这里提出一种“把AI智能体培养成研究生”的工作框架。比喻的重点不是拟人化，而是导师培养中的五个动作：读文献、给方向、教方法、纠错误、记过程。它们分别对应五层外部上下文，并通过“读取、执行、写回、抬高下一次起点”的闭环形成复利。

1 设计目标与总体思路

面向长期科研任务的智能体系统应满足五项要求。第一，知识必须外置，不能依赖某一模型会话的短期上下文。第二，任何非平凡判断都应能回到原始论文、代码、数据或用户明确输入。第三，任务结果必须写回知识库，否则一次高质量回答仍会消失在聊天记录中。第四，知识资产应与具体模型和平台解耦，以便更换模型、电脑或智能体。第五，科学判断、保密边界和最终责任始终由研究者掌握。

表1把研究生培养动作映射到系统组件。这里的“培养”不改变模型参数，而是持续构造高质量上下文。模型可以更换，积累下来的文献综合、项目时间线、失败记录和操作规范仍然保留。

表1 研究生培养动作与智能体知识架构的对应关系

Table 1 Mapping from graduate-student training to the agent knowledge architecture

培养动作	系统实现	主要科研收益
读文献，建立领域全景	文献页、概念页、统一词表	综述随阅读累积，减少重复检索
说明方向和评价标准	常驻个人档案	新会话直接进入工作状态
教方法，形成标准流程	可复用技能与检查清单	同类任务稳定执行，可复现
及时纠错并要求记住	反馈记忆	同类错误不反复出现
记录失败、想法和节点	失败库、想法库、时间线	开题建立在全部历史判断之上

2 五层个人知识架构

LLM Wiki把原始资料、LLM维护的互联wiki和维护规则分开，使知识从“查询时临时拼接”转为“整理一次、持续更新”[8]。针对核物理研究，图1进一步把科研智能体的外部上下文拆成五层。智能体位于架构之上，负责读写和调用工具；研究者控制来源、审查、版本和保密边界。



图1 面向核物理研究的五层AI智能体知识架构与写回闭环。图形结构由AI辅助起草，作者使用Python脚本生成并逐项核对
Fig.1 Five-layer knowledge architecture and write-back loop for a nuclear-physics research agent. The layout was drafted with AI assistance, generated with a Python script, and verified by the author

2.1 L1：纯文本、链接与版本控制

最底层采用Markdown、普通目录和git。选择纯文本不是为了追求简陋，而是为了让人和智能体读取同一份文件。研究者可以用Obsidian等工具浏览链接和图谱，智能体则可直接搜索、读取和修改文件。git记录每次变更，使结论、规则和项目状态能够比较、回滚和审计。原始PDF、代码、数据与评审材料另设只读或受控区域，派生笔记不能覆盖原始证据。

2.2 L2：常驻个人档案

个人档案存放每次会话都需要的稳定信息，包括研究方向、在投论文、常用代码、可用算力、合作关系和工作硬规则。常驻信息应“小而精”，不能把整个知识库塞进系统提示。其功能类似课题组的新生手册，使智能体在收到任务时先知道“我们在做什么、什么算好、哪些操作不允许”。对核物理计算，一个有效档案至少应包含物理正确性优先、代码先审后跑、重计算使用远程资源、数值结果必须与解析极限或已有程序比较等规则。

2.3 L3：概念笔记与统一词表

知识综合发生在第三层。每篇论文先形成带来源的文献页，再按方法、体系、可观测量和研究者或代码实体链接到概念页。概念页不是标签列表，而是随着新文献进入而修订的小型综述。统一词表用于合并缩写、别名和不同语言写法，避免同一概念因“CDCC”“continuum-discretized coupled channels”和中文名称而分裂成多个孤立页面。

这一层与传统RAG互补。RAG适合从大量原始文档中即时找片段[1]，概念wiki则保存已经完成的跨文献综合。前者回答“哪些原文可能相关”，后者回答“已经读过的文献共同说明什么、在哪里矛盾”。对于未精读文献，可增加本地全文词法语料作为候选发现层，但检索未命中不能被当作“无人做过”的新颖性证据。

2.4 L4：技能与读写协议

技能把“怎么做”写成可复用流程。例如，文献入库技能规定如何核对元数据、提取关键数字、检查词表、更新概念页、标记矛盾和追加日志；论文写作技能规定如何建立论证、核实引用和保留出处；数值调试技能规定先检查哈密顿量、单位、通道和边界条件，再检查优化器或拟合指标。技能本身也是版本化文本，可在真实任务中持续修正。公开实现可作为起步模板[9]，但具体schema必须按研究方向和课题组规则调整。

2.5 L5：反馈记忆与闭环

反馈记忆保存用户明确纠正过的规则及其原因。与简单保存聊天历史不同，记忆应经过筛选，只记录可迁移的偏好、边界和失败教训。例如，“修改一个报告时不得自动同步其他报告目录”是一条可执行规则；“今天讨论得很好”则没有长期价值。Reflexion通过语言反馈和情景记忆改善后续试验[4]，这里进一步要求记忆进入可检查的本地文件，并与具体任务来源关联。

五层架构只有在写回时才形成闭环。一次任务结束后，新文献进入文献页和概念页，成功方法进入技能，用户纠正进入记忆，失败路线进入失败库，项目节点进入时间线。下一次会话的起点因此高于上一次，而不是重新接待一个“失忆的新生”。

3 三类操作与文献三层栈

知识库的日常维护可以压缩为入库、查询和体检三类操作。三者都必须留下可审计产物，如表2所示。

表2 知识库三类操作及其审查关口
Table 2 Three knowledge-base operations and their review gates

操作	主要输入	写回产物	人工审查关口
入库 ingest	PDF、预印本、报告、代码说明	文献页、概念页、索引、日志	核对关键公式、数字和元数据
查询 query	研究问题与限定条件	带来源的回答、比较表或综合页	判断物理解释和适用范围
体检 lint	全库frontmatter、链接与时间线	矛盾、孤页、断链、陈旧声明清单	决定修复、合并或保留分歧

文献工作应采用“发现、全文、综合”三层栈。第一层通过INSPIRE、arXiv、Crossref等在线数据库发现和核实论文。第二层保存可批量搜索的本地全文语料，用于投稿前扫描可能漏引的关键词、方法名和反应体系。第三层只放研究者已经消化的wiki综合。三层不能互相冒充：在线搜索结果不是已读知识，本地词法未命中不是新颖性证明，wiki摘要也不能替代原文中的公式和表格。

每条引用还应维护来源台账，至少标明候选从何处发现、元数据由哪个权威记录核验、是否已精读、具体声明由哪一页或哪一段支持。对载荷较高的结论，可采用跨模型交叉检查，但交叉检查的输入必须满足保密要求。多个模型给出相同答案并不自动构成真值，最终验证仍应回到原始资料、独立数值基准和研究者判断。

最小可行系统并不复杂：一个原始资料目录、一个Markdown知识库、一个可读写文件的智能体和一份维护schema即可起步。随着规模增长，再增加统一词表、自动索引、定期lint、本地全文检索和跨模型验证。先从当天读的一篇论文开始，比一次性设计庞大平台更可靠。

4 核物理研究中的部署案例

该架构已用于核反应理论、光学势统计推断、散射模拟器和论文项目管理。截至2026年7月，两个个人wiki形成了表3所示规模。约6.2万篇nucl-th全文构成离线候选检索层，571篇精读文献构成可综合层，个人研究档案则保存论文、项目、合作者、方法、失败和时间线。图谱规模用于说明系统能够长期维护真实研究上下文，不等同于受控效率实验。

表3 核物理个人知识库的部署规模（截至2026年7月）
Table 3 Deployment scale of the personal nuclear-physics knowledge base as of July 2026

指标	数量	含义
精读文献	571篇	进入可综合wiki并保留来源
实体页	365页	作者、代码、实验与概念实体
方法页	195页	按统一词表聚合的方法综述
关系图谱	1425个节点，6432条链接	跨论文、方法、体系和项目连接
本地全文语料	约6.2万篇	nucl-th候选发现与漏引扫描
个人论文档案	97页	已发表、在投、草稿和被拒项目
合作者档案	38页	合作历史、研究方向和沟通背景

4.1 从通用回答到带出处的研究回答

一个测试问题是：“我读过的文献里，谁的结果与Koning-Delaroche全局光学势不一致？”裸模型只能给出全局光学势的一般介绍，并不知道“我读过的”具体范围。接入知识库后，智能体先读索引和光学势概念页，再定位到DREAM贝叶斯校准记录。该工作对20 MeV的d+58Ni弹性散射同时校准18个光学势参数，数据把氘核表面吸收的后验均值提高到Koning-Delaroche值之上约36%[10]。回答同时返回文献页、原始预印本和项目时间线，研究者可以立即检查适用体系和模型假设。

这个例子说明，知识库的作用不是让模型“知道更多常识”，而是把答案限制在研究者真实读过、可追溯的证据范围内。库中没有的内容应明确标记为外部补充，而不是以熟练语气掩盖来源缺失。

4.2 从文献积累到综述初稿

第二个案例是一篇三体核反应综述初稿。智能体先从个人文献wiki确定论证骨架和已读引用，再进行外部发现与元数据核实，最后生成58页初稿和199条参考文献。其中181条挂接到已读wiki来源，另外18条被单独列入“待精读清单”，同时生成逐条引用台账。这个产物仍需作者检查物理判断、公式和行文，但它把“哪些引用来自长期阅读、哪些是为本稿临时补充”清楚分开。

这里不把页数或引用数当作质量指标。真正有价值的指标是可追溯率、漏引候选是否显式暴露、同一任务能否从相同版本的知识库复现，以及作者能否快速定位到支撑某个声明的原始证据。

5 局限、失效模式与安全边界

5.1 摘要损失与过度压缩

论文摘要页会丢失推导细节、适用条件和负结果。外围文献可以轻量入库，但关键论文必须保留精读标记、章节定位和关键数字。任何影响正文物理结论的公式、表格或图中数值，都应回到原文核对。摘要层是导航层，不是新的权威来源。

5.2 概念分裂与陈旧综合

统一词表不能消除所有别名，概念页也可能因新结果进入而陈旧。定期lint应检查重复slug、孤立页面、断链、互相矛盾的绝对声明和久未更新的综合。自动索引区与人工综合区应分开，避免程序重建索引时覆盖研究判断。

5.3 单源错误与反馈放大

智能体可能把一次错误概括写回库中，并在后续任务中反复引用，形成“自我引用式确信”。因此，重要结论要标记单源或交叉验证状态；引用元数据必须从权威数据库重新获取；数值结果必须与独立程序、解析极限或公开基准比较。跨模型一致只能降低某些模型特有错误，不能替代物理验证。

5.4 维护成本与并发冲突

知识库的复利依赖持续维护。入库、查重、合并概念和体检都需要时间。当多个智能体同时修改同一档案或索引时，还会出现覆盖和时间线丢失。解决方法不是增加更多自动化层，而是缩小并发写入范围、使用git分支或提交审查，并让一个明确流程拥有公共索引的最终写权限。

5.5 隐私、保密与平台边界

未发表论文、审稿材料、合作者邮件和内部数据必须分级存放。核心wiki可本地优先，公开资料、私有项目和永久保密材料使用不同仓库或访问规则。任何外部模型调用前都应检查数据使用条款。特别是审稿和编辑材料，不能上传到会把输入用于训练或权利不清的服务。

6 评价指标与科研治理

科研智能体不宜只用任务完成率评价。至少还应检查五个维度：其一，来源可追溯率，即关键声明能否回到原始资料；其二，版本可复现性，即相同仓库版本能否重建结果；其三，纠错保持率，即明确纠正过的错误是否在新会话中复发；其四，科学有效性，即数值、单位、近似和物理图像是否通过独立基准；其五，维护成本，即每次入库和体检的人工时间是否低于后续节省的重复劳动。

AI使用还需要明确披露。美国物理学会2026年更新的期刊政策允许在研究和写作中使用AI工具，但要求人类保持判断和责任；实质性使用应说明工具名称与版本、协助方式以及作者如何指导和核验，保密评审材料不得上传到不受限工具[11]。这一原则同样适用于核物理中文期刊：AI不能署名，作者必须核对全部科学内容，并在方法、图注或致谢中按实际使用范围披露。

对课题组而言，治理规则应写进schema而不是停留在口头约定。建议至少包含数据分级、允许调用的工具、重计算审批、引用核验、图像完整性、跨模型验证和最终签字责任。这样，vibe coding带来的开发

速度才能转化为可复现科研，而不是制造更多无法追踪的脚本和结论。

7 结语

面向核物理研究的AI智能体，真正稀缺的不是一次会话里的聪明，而是跨会话保存研究上下文、按固定流程工作、接受纠错并把成果写回的能力。纯文本与版本控制提供可迁移地基，个人档案提供方向和标准，概念wiki承担文献综合，技能固化科研流程，反馈记忆防止重复犯错。五层共同构成一个由研究者控制的外部认知系统。

“把智能体培养成研究生”因此不是要求AI替代学生或作者，而是强调长期指导、明确标准、持续反馈和实验记录。模型只是可替换的推理引擎，个人知识库才是研究者积累下来的家底。只要坚持来源优先、物理优先、写回闭环和人工负责，这一框架可以把一次性的AI辅助转化为可审计、可复用、随研究共同成长的基础设施。

致谢 作者在论文结构整理、初稿生成、参考文献格式核查、图形脚本起草和Word排版中使用OpenAI Codex（GPT-5，访问日期2026年7月17日）。作者依据报告原始材料和权威数据库逐段核对文本、数据、图件和文献，并对全部科学判断和最终内容承担责任。

参考文献

- [1] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems 33. 2020. <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [2] YAO S, ZHAO J, YU D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[C]//The Eleventh International Conference on Learning Representations. 2023. https://openreview.net/forum?id=WE_vluYUL-X.
- [3] PARK J S, O'BRIEN J C, CAI C J, et al. Generative Agents: Interactive Simulacra of Human Behavior[C]//Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology. New York: ACM, 2023: 1-22. DOI: 10.1145/3586183.3606763.
- [4] SHINN N, CASSANO F, GOPINATH A, et al. Reflexion: Language Agents with Verbal Reinforcement Learning[C]//Advances in Neural Information Processing Systems 36. 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html.
- [5] BRAN A M, COX S, SCHILTER O, et al. Augmenting large language models with chemistry tools[J]. Nature Machine Intelligence, 2024, 6: 525-535. DOI: 10.1038/s42256-024-00832-8.
- [6] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J]. Nature, 2023, 624: 570-578. DOI: 10.1038/s41586-023-06792-0.
- [7] LU C, LU C, LANGE R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. arXiv:2408.06292, 2024[2026-07-17]. <https://arxiv.org/abs/2408.06292>.
- [8] KARPATY A. LLM Wiki: A Pattern for Building Personal Knowledge Bases Using LLMs[EB/OL]. 2026-04-04[2026-07-17]. <https://gist.github.com/karpathy/442a6bf555914893e9891c11519de94f>.
- [9] LEI J. research_LLM_wiki: Cross-harness agent skills for maintaining a personal literature wiki and research portfolio[CP/OL]. 2026[2026-07-17]. https://github.com/jinleiphys/research_LLM_wiki.
- [10] LEI J. High-Dimensional Bayesian Calibration of Expensive Nuclear Models with Differentiable Emulation[EB/OL]. arXiv:2605.30980, 2026[2026-07-17]. DOI: 10.48550/arXiv.2605.30980.
- [11] APS JOURNALS. Appropriate Use of AI Tools[EB/OL]. 2026-06-17[2026-07-17]. <https://journals.aps.org/authors/appropriate-use-ai-tools>.