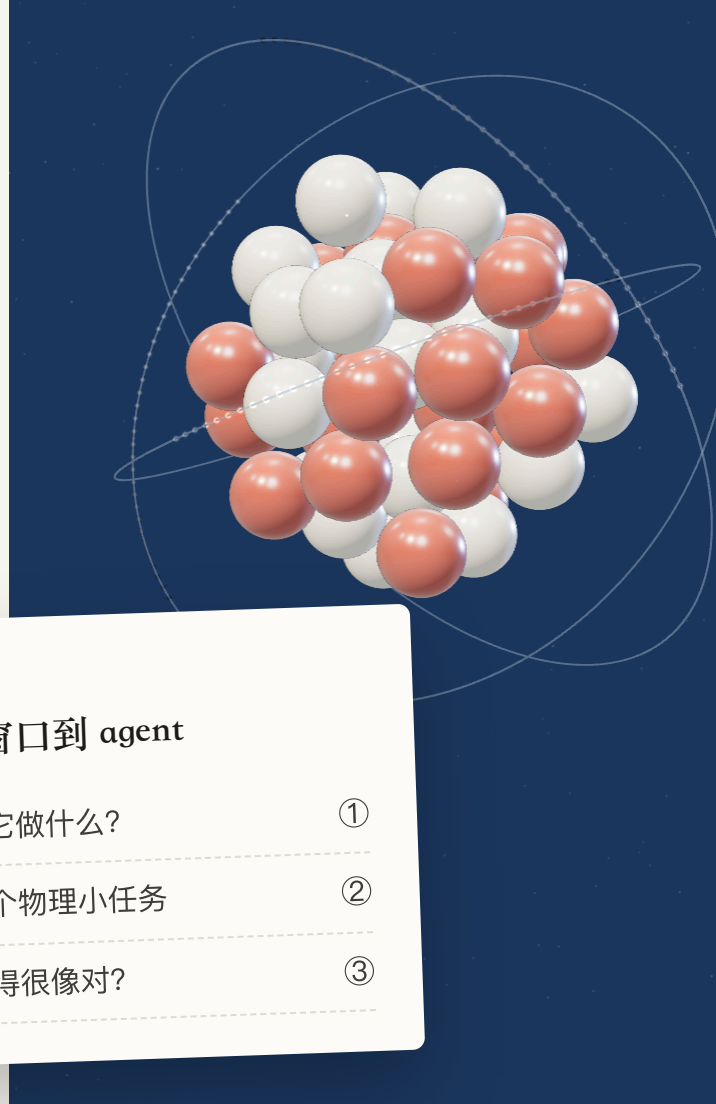
第五届机器学习会议培训班 · 2026.10.30

Using AI in Research:

Lessons from FUSION

金磊 · Jin Lei

同济大学物理系



TODAY

从聊天窗口到 agent

① 我平时让它做什么?

② 现场做一个物理小任务

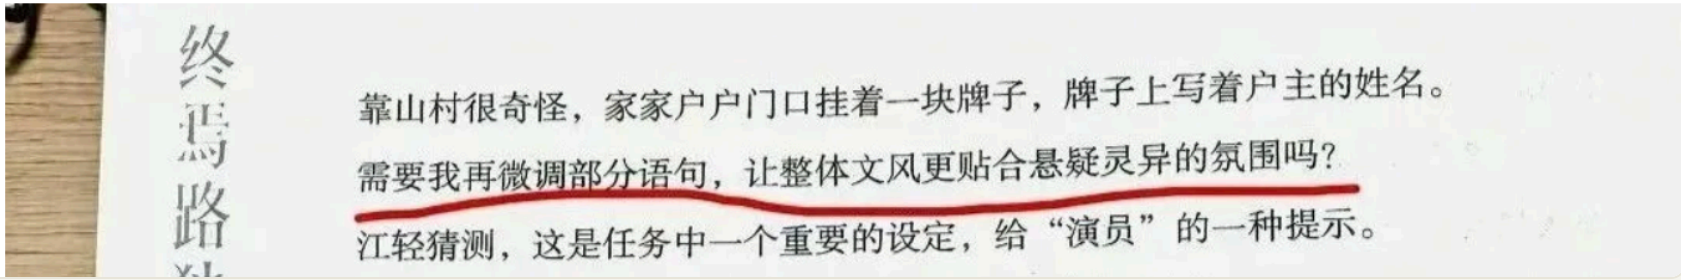
③ 它怎样错得很像对?

哪句话不该出现在书里？

A chat reply made its way into the finished text

“需要我再微调部分语句吗？”纸质书中出现AI提示词，警示我们什么？

Original 任飞帆 人民日报 Oct 14, 2026, 2:45 PM 北京



> “需要我再微调部分语句……”是 AI 对用户说的话，被复制进了正文。

用网页写代码，你在当搬运工

Copy code, run it, paste the error, repeat

AI
给一段代码
聊天窗口

>

你
复制、保存、运行
你电脑上的文件

>

你
把报错贴回去
回到聊天窗口

>

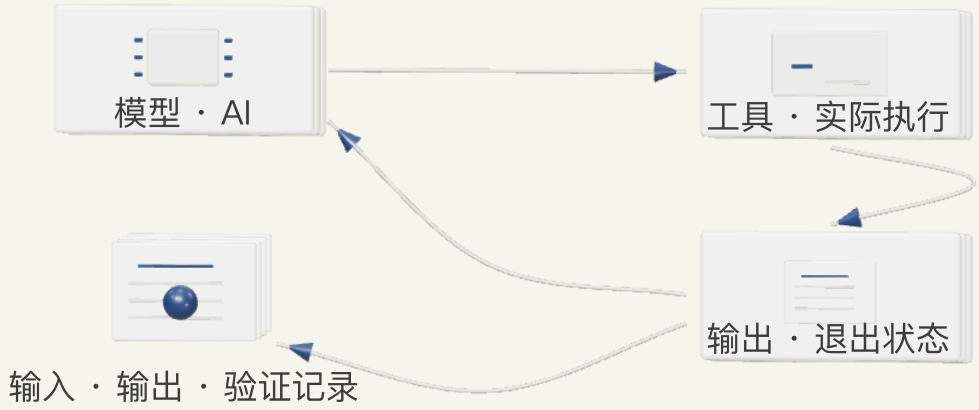
AI
给修改版
再来一次

它看不到你的文件，跑不了你的程序，也看不到运行结果。
它知道的一切，都是你贴给它的。

agent：让模型自己读文件、跑程序、看结果

Agent = a model working with tools and feedback

agent（智能体）：能调用工具执行操作、读取结果、再决定下一步的 AI。常见的有 Claude Code、Codex、OpenCode。



教学示意；纸张代表材料，连线代表操作依赖。

点击继续 · 5 / 5

保存结果文件

检查通过后，保存实际输入、原始输出和验证记录。

什么活值得交给 agent?

Choose the workflow by what the task touches

你要做的事	网页聊天	agent
理解一个概念、讨论思路、改一段英文	够用	不必
对照两个长文件（校样、两版稿子）	能上传，但改完还得你搬回去	直接在你的目录里对照、写结果
改程序、运行、看报错、再改	你当搬运工	它自己循环
一批输出整理成表、画图	贴不下	读整个目录
查文献、核对引用	不联网时凭记忆，会编	调数据库，存原始记录

> 判断标准只有一个：这件事要不要碰你的文件、跑你的程序、查外面的数据库。

01

PART 01

我最近让它做的三件事

校样、参考文献、预印本：都是真实记录，都是网页聊天做不了的

校样里，^{16}O 变成了 ^{6}O

Case 1 · checking an APS page proof against my source

2026-10-13 · PRC 114, 044620 校样 · 真实记录

我交给它的事（大意）

这是 APS 发来的校样 PDF，这是我投稿的 .tex 和 .bib。

逐处对照，列出必须改的地方；35 条参考文献逐条查库；把给编辑的回复写好。

✓ 它找到的

源文件处处是 ^{16}O、^{93}Nb；校样只有第一次对，之后质量数都丢了第一位：

$^{6}O(d,p)^{17}O \rightarrow {}^{16}O(d,p)^{17}O$

$^{3}Nb(d,pX) \rightarrow {}^{93}Nb(d,pX)$

共 11 条改正，含 2 处“+n”被排成下标。35 条参考文献全部正确；公式 (1)–(18) 无变化。

我看的是什么

每一处它都放大到 300 dpi 截图确认。

每条文献写明查的是哪里：CrossRef、INSPIRE、Springer。

我定的规矩：只改排版错误，APS 体例的改动不碰。

网页聊天怎么做? 文件可以上传，但它碰不到你的源文件目录；结果要你一处处搬回去、对回原文。

它交回来的：一份可以直接发出去的回复

The deliverable is a file, not a chat answer

```
Corrections (typesetting errors: the mass
numbers 16 and 93 have lost their first digit;
the source has ^{16}O and ^{93}Nb throughout):
1. Line 190: "^{6}O(d,p)^{17}O"
           -> "^{16}O(d,p)^{17}O".
 ...
6. Line 386: "^{3}Nb(d,pX)" -> "^{93}Nb(d,pX)".
 ...
Queries:
Q3. The added article titles have been checked
    against the publisher records and are correct.
```

这个文件里有三部分

参考文献核对表：35 行，每行写明查的哪个库。

必须改的排版错误：11 条，每条带校样行号。

给编辑的回复：可以直接粘贴。

还有一段**“不用管的地方”**：APS 体例改动，它列出来，但建议不改。

原文节选，来自 proof_corrections_2026-10-13.txt。正式出版版上，这 11 处都已改正。

45 条参考文献，一条一条去查库

Case 2 · re-checking a bibliography before production

2026-09-28 · PRC 114, 044618 接收后、交付生产前 · 真实记录

我交给它的事（大意）

论文接收了，交付排版前，把正文实际引用的每一条文献重新核对一遍。

不许凭记忆，不许用上次的缓存。

它怎么做的

43 条有 DOI：逐条在线取 CrossRef 记录，比对题目、**每位作者的姓及顺序**、卷、起始页、年份。

题目里的同位素质量数单独再比一遍。

没有 DOI 的 2 条：会议论文查 INSPIRE，Feshbach 的书查 Open Library。

结果：45/45 真实，没有不符。

留下的证据

查询脚本、每条的原始返回，都存在论文目录里。

它还会判断：011601(R) 的“(R)”是快讯标记，不是错误。

网页聊天怎么做？ 它会凭记忆回答“看起来都对”。AI 编参考文献，恰恰就是这样编出来的。

公开的预印本把 Kolmogorov 写成了“K. A. N.”

Case 3 · a stale arXiv version nobody had looked at

2026-09-04 · 刘昊、金磊、任中洲，PRC 111, 024316（2025）· 真实记录

起因

我的笔记里，这篇论文没有记 arXiv 号。

它用 DOI 去 INSPIRE 查，发现有：arXiv:2407.20737。

公开的 v2 是接收后第二天传的，比校样早，校样上的改正都没进去。

公开版里的问题

正文说“Figure 1”，应该是 Fig. 2。

同一个标签定义了两次，引用指错了图。

Kolmogorov 被印成 “K. A. N.”

Arnol'd 的论文署成了编者的名字。

Fisher–Yates 洗牌算法，引到了一个形式化证明库的条目。

它交回来的

从最终源文件重建 v3，在空目录里从头编译：0 个未定义引用。

还查出正式出版版的表 II 把 A_{sym} 印成了 A_{vol}，放大到 300 dpi 确认。

网页聊天怎么做？ 你得先知道有这个预印本，再自己下载两个版本，逐条对。这种活没人有时间做，公开的 v2 就这样挂了十九个月。

三件事有什么共同点?

What the agent did, and what I still did

	它要读的	它要调的	它留下的证据	我做的
校样	PDF + .tex + .bib	CrossRef、INSPIRE	行号、放大截图	定规矩：只改错误
参考文献	45 条引用	CrossRef 43 次	脚本、原始返回	定标准：逐字段比
预印本	两个版本、源文件	INSPIRE、编译器	编译记录、对照表	决定传不传

> **它做的是读、查、跑、对；要什么标准、结果信不信，是我的事。**

02

PART 02

现场：一个物理小任务

n–p 方势阱的 s 波相移：让它写、跑、画、交，然后我们来验收

现场：准备一个文件夹，启动 agent

One folder, one command

```
square-well-task/
  README.md        ← 任务和常数
```

```
cd square-well-task
claude          # 或 codex / opencode
```

README.md 里写了什么

n–p 在半径 R = 2 fm 的方势阱里。

调势阱深度，让氘核结合能等于 2.2246 MeV。

算 s 波相移 $\delta_0(E)$：数值解和解析解。

给了 $\hbar c$、m_n、m_p。没写该用哪个质量。

> 今天用 Python。安装、登录、终端用法都在材料包的 SETUP.md 里。

第一句：先读，说清打算，不动手

Prompt 1 · inspect before acting

PROMPT 1 · 可以直接复制

请读 README.md。

告诉我要算什么物理量、用什么方程和边界条件、打算怎么验证结果。

现在先不写代码，也不运行。

看它说的是不是 README 里的东西：半径、结合能、哪几个能量。
它说的方程和你课本上的一样吗?

第二句：写程序、跑、画图、存结果

Prompt 2 · ask for files and a completed run

PROMPT 2 · 可以直接复制

用 Python 写 square_well.py 并实际运行：

先调深度 V_0 使束缚能等于 B_d；

在 E = 0.1, 1, 5, 10, 20, 50 MeV 用 Numerov 数值解和解析解各算 δ_0，列表比较；

画 $\delta_0(E)$ 存到 results/phase_shift.png，数值和 V_0 写进 results/summary.txt。

做完告诉我运行命令和你做了哪些检查。

没运行就不算做完。缺 numpy 之类的包，先告诉我，再装。

它写的代码，只看三处

You don't have to read every line, but read these

```
MN, MP = 939.56542, 938.27209    # MeV
mu = MN * MP / (MN + MP)         # ① 用的哪个质量?

u[0], u[1] = 0.0, h              # ② r = 0 处 u = 0
for i in range(1, n):            #    Numerov 往外推
    u[i+1] = (2*u[i]*(1 - 5*h**2*w[i]/12)
              - u[i-1]*c[i-1]) / c[i+1]

# ③ 势外匹配 u = A sin(kr + δ), 取最外两点
t = (u[n-1]*sin(k*r2) - u[n]*sin(k*r1)) / \
    (u[n]*cos(k*r1) - u[n-1]*cos(k*r2))
```

你要会看的

① **质量：**两体相对运动，$\hbar^2/2\mu$ 里的 μ。

② **边界条件：**约化径向函数 u(0) = 0。

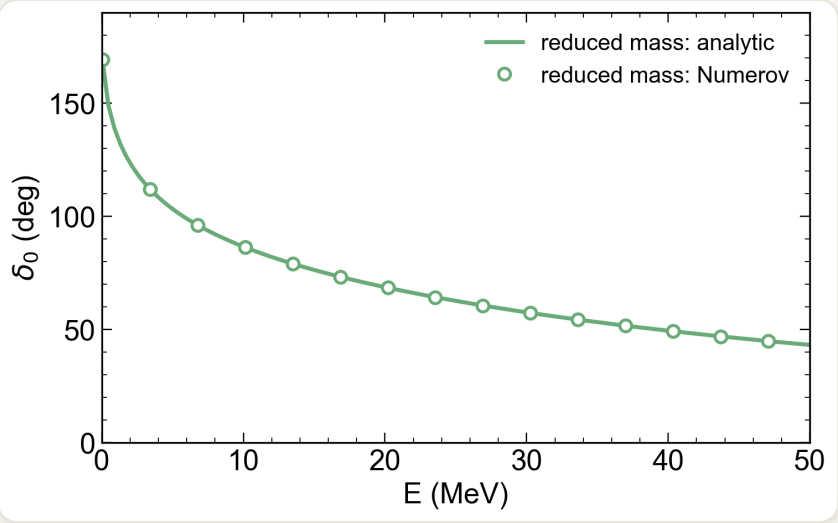
③ **匹配：**在势外面，用自由解读出相移。

循环怎么写、数组怎么存，可以不看。物理在哪几行，你得知道。

据 reference/square_well.py（备课参考实现）简化；现场生成的代码写法会不同，三处一样要找。

打开文件夹：图、表、说明

Live demo · open what it delivered



参考结果（备课实测）

V_0 = 36.567 MeV

六个能量上，数值解与解析解

最大差 0.0059°（在 1 MeV）

点和线重合。

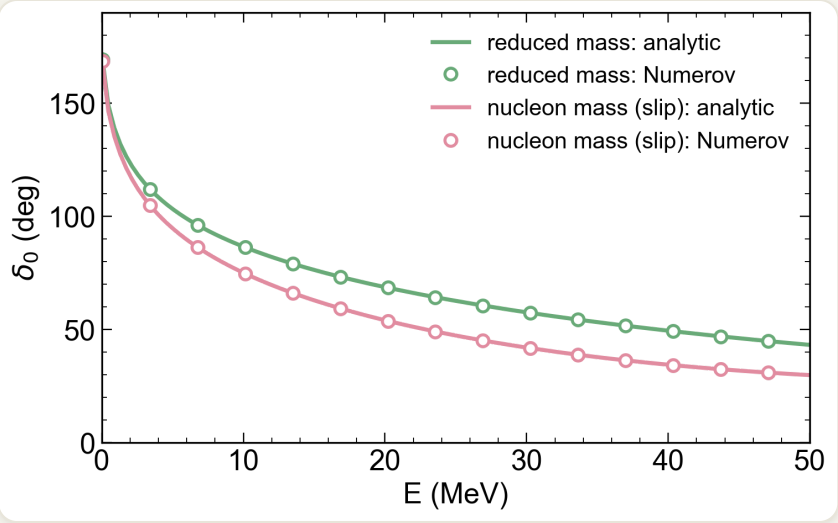
任务完成了。

可以交了吗?

横轴为质心系能量，纵轴为 s 波相移；点为 Numerov，线为解析解。数字来自 reference/square_well.py 的实际运行，Julia 原版逐点对照到 11 位有效数字。

换成核子质量，检查照样通过

Two solvers can share the same wrong assumption



我故意改了一处

相对运动该用约化质量

$\mu = m_n m_p/(m_n+m_p) \approx 469$ MeV，

改成核子质量 $m \approx 939$ MeV。

重新拟合深度：$V_0 = 20.986$ MeV，结合能照样对。

数值解和解析解也照样重合，最大差 0.0037°。

两边用的是同一个错质量，所以彼此吻合。“数值对上解析”查不出这个错。

用一个没参与拟合的量来查

Prompt 3 · check against physics the fit did not use

PROMPT 3 · 追问

再算三重态散射长度 a_t，和实验值比较。

告诉我你用的是哪个质量，为什么。

	约化质量	核子质量	实验
结合能 B_d	2.2246 MeV（拟合）	2.2246 MeV（拟合）	2.2246 MeV
散射长度 a_t	**5.356 fm**	**4.105 fm**	≈ 5.42 fm

结合能是拟合进去的，当然对；a_t 没参与拟合，一比就分开：差 1% 和差 24%。

每一种检查，各回答一个问题

Implementation, setup, and model adequacy

想知道什么	刚才怎么查的	查不出什么
它真的跑了吗?	打开文件，用它给的命令再跑一次	算得对不对
方程解对了吗?	数值解对解析解	两边共用的错设定
设定和模型整体对吗?	没参与拟合的量：a_t 对实验	偏差来自设定还是模型
模型够用吗?	更多没拟合的数据，带误差	

> AI 说“我已经验证过了”，要问它：验证的是这一列里的哪一行?

03

PART 03

它也会错，而且错得很像对

两次真实的错：不是胡编，是合理地读错了证据

它说“检查从六月起就坏了”，坏的是它自己的检查

Case 4 · an empty result read as “nothing there”

2026-09-09 · 我的文献 wiki 每周自动检查 · 真实记录（页底是今天备课时同一条命令的报错）

它的报告

每周自动检查从 6 月 29 日起就静默失败了，两个多月没有出报告。

听起来很具体，还附了“佐证”。

实际情况

这台电脑上的 `ls` 被换成了另一个工具 eza，`-t` 参数意思不同。报错被丢掉，结果是**空**。

它把“空”读成了“没有报告”。“佐证”按字母排序，碰巧只显示 6 月的文件。

最新报告其实是 9 月 7 日的，检查一直正常。

我学到的

失败时也返回空的检查，和“确实没有”分不出来。

先在一个确定有东西的地方，试一下检查本身。

```
eza: Flag -t needs a value (choices: modified, changed, accessed, created)
```

四份记录说法一致，四份都错

Case 5 · a cleanup that spread the error it was sent to remove

2026-09-04 · FUSION 项目 README · 真实记录

背景

FUSION 里有 20 个核物理程序的安装脚本。

8 月，我在一台干净的服务器上把 20 个全部从零装了一遍，结果记在一张表里。

9 月，我让它更新 README 里过时的说法。

✕ 它做了什么

没去读那张表，而是抄了开发日志里的一句文字总结：

“13 个干净通过，4 个缺依赖停下”

写进了中英文两个 README 和 TODO。连同原来的日志，四份记录互相一致。

发现靠的是算术：13 + 4 = 17，不是 20。

✓ 表里的实际结果

8 个无人值守直接通过

4 个缺依赖，正确地拒绝安装

5 个修了可移植性问题后通过

3 个是测试框架的问题，与脚本无关

规矩： 数字要从产生它的原始结果里取；一致不等于正确。这一次，凑巧加起来不等于 20，才被发现。

04

PART 04

把吃过的亏写下来

skill：一份它每次都会读的操作规程。从查文献，到 FUSION

把查文献的规矩写成 skill

literature-search: the workflow behind Case 2

找线索

先查已有笔记

没有线索，再搜候选

>

调工具

取数据库记录

INSPIRE / CrossRef / arXiv

>

核对

是不是要找的那篇

题目、作者、年份

>

写文件

生成 BibTeX

只用记录返回的字段

每一步都有规矩

笔记只给线索，也要重新查库。
缺字段标 UNVERIFIED，不凭记忆补齐。

查不到时怎么办

报告无匹配、多个候选或网络失败。
没核实的条目，不混进正式引用。

SKILL.md 长什么样

A teaching excerpt from literature-search

```
name: literature-search
description: 搜索并核实科学文献；
  查论文、DOI 或生成 BibTeX 时使用。
```

先查已有文献笔记，取得候选线索。
调用数据库工具，读取原始记录。
核对题目、作者、年份是否匹配。
引用字段只取自本次查询结果。
缺项标 UNVERIFIED，不猜 DOI。
保存引用、记录链接和检索日期。

三部分各做什么

名称和说明：告诉它什么时候用。

操作步骤：调什么工具、查什么、何时停。

脚本：实际访问数据库的程序，
例如 scripts/verify_doi.py。

没有训练新模型，
只是把做事的方法交给它。

中文教学节选；完整 skill 还有分支流程。材料包 literature/ 里有一次真实查询的原始记录。

现场：让 skill 查一篇论文，存下原始记录

Run the lookup and open its files

演示任务

使用 literature-search，核实 DOI `10.1103/PhysRevC.97.011601`。

保存数据库原始记录、BibTeX 和核对说明。查不到的字段不要补写。

它交回三个文件

crossref-record.json：数据库原样返回。

references.bib：只用返回的字段生成。

verification.md：查了哪里、何时、缺什么。

备课时就碰到一个坑

脚本给出的页码是**空**：PRC 用文章号，CrossRef 放在 article-number，脚本只读 page。原始记录里有 011601，从那里取，不看着 DOI 猜。

备课查询：2026-10-20，CrossRef，禁用缓存；记录在材料包 literature/results/。断网时打开它，并说明是备课结果。

FUSION：核物理程序的 skill

Edit a verified input, reproduce a known benchmark

26 个 skill，其中 20 个驱动公开的核物理程序。

FRESCO、TALYS、SKY3D……每个 skill 带一份核对过的输入和一个已知结果。

它照着做

在核对过的输入上**改**，不凭记忆**写**。

跑完先复现已知结果，到指定精度。

它替不了的

复现已知结果，只说明程序装对了、跑对了。

研究什么、模型合不合适、结果怎么解释，还是你的判断。

两个程序对不上，查出了一个公开代码的 bug

Case 6 · disagreement is information

2026-09 · 核反应程序对照 · 真实记录，暂不公开程序名

做了什么

同一个 (p,n) 反应，同一组输入，一个公开的散射程序和 FRESCO 各算一遍。

发现什么

对不上。逐项排查，那个程序漏掉了自旋翻转项。

后来

联系作者，作者独立确认，已经修复。

方势阱那里，两边对上了也可能都错；这里，对不上本身就是信息。
AI 负责跑、比、定位；比什么、信哪个，靠物理。

授权之前，看它准备做什么

Permissions and privacy

它会问你要权限

读哪些文件、写哪些文件、运行什么命令。

看不懂就先让它解释，
不要一路点“同意”。

文件内容会发给模型服务

文件在你电脑上，不等于内容不出门。

未发表的数据、审稿稿件、合作者的代码，
先确认能不能给。

> 第一次先在一个副本目录里练。

练习：用你自己的课题写一条任务

3 分钟写，3 分钟和旁边的同学互换

YOUR FIRST TASK

读什么：哪个目录、哪些文件？

做什么：具体完成哪一步？

不许做：哪些文件不改？遇到什么先停下？

交什么、怎么验：保存哪些文件？用哪个**没参与计算的量**来检查？

可以选：整理一批输出画图、改一个老程序加参数扫描、核对一篇稿子的参考文献。
不要选“帮我把论文写完”。

回去以后

Three things to take home

① **要碰文件、跑程序的活，交给 agent**

讨论概念继续聊天就好；来回复制粘贴的活，让它自己读、自己跑。

② **看证据，不看它说“验证过了”**

问一句验证的是哪一种；物理上找一个没参与拟合的量。

③ **吃过的亏，写成 skill**

写清步骤、工具、什么时候停；试跑，再改。

课后材料

Everything from today, ready to run

student-materials.zip

square-well-task/：今天的任务、三条提示词、
Python 参考程序和输出。

literature/：skill 节选和一次真实查询的原始记录。

SETUP.md：安装、登录、终端入门。

回去先做这个

把今天的方势阱自己跑一遍。

然后故意让它用核子质量，
看它自己能不能发现。

问答

你准备让它帮你做的第一件事是什么?

备用：从官方入口安装和登录

Follow the guide for your operating system

工具	安装与首次配置	已装好之后
Codex	官方 CLI 入口，按账号提示配置	练习目录中运行 codex
Claude Code	官方 Quickstart，按系统选择安装方式	运行 claude，完成首次登录
OpenCode	官方文档，选择版本并配置模型服务	运行 opencode，按文档连接服务

只需要一个工具能用。Python 3 加 numpy、matplotlib 即可跑今天的任务。

备用：项目说明文件的例子

Standing instructions the agent reads every time

```
# 本项目的工作约定
- data/ 存放原始数据，不修改。
- 新结果保存到 results/。
- 运行后报告命令、输出位置和做了哪些检查。
- 数字从原始输出里取，不从文字总结里抄。
- 缺少环境或不清楚定义时，先说明，不编造数据。
```

Claude Code 读 CLAUDE.md，Codex 读 AGENTS.md；放在项目根目录，确认它实际读到了。

备用：实验数据的误差被存成了 0

A parsing defect that inflated a result

发生了什么

从 EXFOR 读实验数据时，解析程序把 8 组 (p,n) 数据的误差存成了 0。

误差 0 又被截到 0.5% 的下限：这 8 组只占数据点的 15%，却占了 Fisher 信息迹的 88%。

结论一度被放大。

怎么防

读进来的数据，先打印每组的误差范围。

出现 0、负数、NaN，先停下来问。